

졸업프로젝트 팀 03 (Alltology) — 「RAG에서 지식 충돌 완화를 위한 Preference Learning 기반 정렬 연구 (Conflict-Aware PA-RAG)」 지도 교수 의견서

지도교수: 황의원

본 팀은 PA-RAG(NAAACL 2025)를 기반 논문으로 삼아, 해당 연구가 다루지 않은 knowledge conflict(검색된 외부 근거와 모델 내부 지식의 충돌) 상황을 preference learning으로 정렬하는 방향을 제안하였습니다. 기반 논문의 미해결 지점을 정확히 짚어 연구 문제를 도출하였고, 이를 "내부 지식과 외부 지식 활용의 결합"이라는 문제로 자연스럽게 연결한 점에서 문제 설정이 타당하다고 판단됩니다.

진행 과정에서 본 팀은 학기 중 매주 토요일 정기 팀 회의를 꾸준히 이어왔으며, 여름방학에도 교수 면담을 수요일로 먼저 제안하고 토요일 팀 회의 또한 동일하게 유지하기로 하였습니다. 또한 학기 초 첫 면담에서 권하였던 진행 방향 — 여름방학 이전에 연구 방향을 확정하고 예비 실험까지 진행한 뒤 방학부터 본격적인 실험에 착수한다는 일정 — 을 충실히 이행해 왔다고 생각합니다.

연구가 진행되는 동안 다음과 같은 방향을 지도하였으며, 팀이 이를 적절히 수용하여 최종 면담을 진행하였습니다. 첫째, 연구 framing을 단순 성능 비교가 아니라 한계 분석(어떤 유형의 충돌이 학습으로 내재화되고 어떤 유형이 한계인가)으로 가져갈 것을 권하였습니다. 이는 학부 수준에서 더 정직하고 방어 가능한 구조이며, 사전 가설을 명시한 뒤 검증하는 형태로 설계하도록 지도하였습니다. 둘째, 학부 자원의 한계를 고려하여 문제 범위를 명시적으로 제한할 것을 권하였습니다. Full fine-tuning은 직접 수행하지 않고 PA-RAG 원논문 수치를 인용 비교군으로 활용하며, conflict type을 3~4개로 한정하되 "대표 유형을 커버한다"는 논리로 결론짓는 방식이 적절하다고 보았습니다. 셋째, 데이터 전략에 대해 자체 제작보다 공개 벤치마크 활용을 우선하고, 자연 conflict는 수집 부담이 크므로 case study 수준의 정성 분석으로 한정하도록 조언하였습니다.

지금까지 본 팀은 Base RAG 파이프라인과 conflict-aware prompting을 동일 코드베이스에서 비교 가능한 형태로 구현 완료하였고, 소규모 모델(phi-2) 기반 파일럿을 통해 프롬프트 차이만으로 충돌 상황의 답변이 달라질 수 있다는 초기 신호를 확인하였습니다. 이 파일럿은 표본이 작아 방법론의 효과를 입증하는 단계는 아니나, 본 실험 진행의 타당성을 뒷받침하는 사전 검증으로서 충분하다고 판단됩니다. 아울러 연구 페이지와 데모 환경을 직접 구축·공개함으로써 구현 역량과 팀 협업 과정을 외부에서도 확인할 수 있도록 한 점은 높이 평가할 만합니다.

데이터와 연산 자원 측면의 기반도 상당 부분 갖추어진 상태입니다. 평가·학습에 활용할 공개 벤치마크 후보군(ClashEval, ConflictBank, WikiContradict 등)이 학습용·평가용·정성분 석용으로 활용 계획이 잘 구성되어 있으며, DPO 학습에 필요한 연산 자원 또한 예산이 확보되어 현실적인 실험 진행 계획이 마련된 상황이라고 판단됩니다. 따라서 앞으로의 핵심 과제는 자원 조달이 아니라 방법론의 정합성에 있습니다. 구체적으로 (1) chosen/rejected를 결정하는 resolution rule의 학술적 정당성 확보 — 라벨이 자명한 합성 케이스로 학습을 한정하는 우회 전략의 타당성, (2) 합성 conflict로 학습한 정렬이 자연 conflict로 얼마나 전이되는지의 검증, (3) conflict 정렬이 기존 정렬 기준 (informativeness 등)을 훼손하지 않는지의 trade-off 측정이 남아 있습니다.

이러한 과제들은 여름방학 정기 면담을 통해 단계적으로 점검할 예정이며, general 도메인에서 먼저 결과를 확보한 뒤 의료·생활검색 등 특정 도메인으로 확장하는 순서로 진행하도록 지도하였습니다. 더불어 연구가 일정 수준 이상 진척될 경우, ACL, EMNLP, NAACL 등 자연어처리 분야 주요 학회나 관련 워크숍에의 논문 투고를 장기 목표로 두고 있습니다. 또한 본 졸업 프로젝트에 관심 있는 본 연구실 석사 과정 학생과의 협업을 연결하여 연구의 확장 가능성을 넓히는 방안도 함께 고려하고 있습니다.

종합적으로 본 연구는 기반 논문의 명확한 확장점, 정직한 범위 설정, 그리고 충실한 사전 구현을 갖추고 있어 졸업프로젝트로서 적절하다고 판단합니다.

2026년 06월 01일

지도교수 : 황의원

