ALLTOLOGY

EWHA · CAPSTONE DESIGN 2026 · RESEARCH TRACK

기억과 문서가 다를 때, LLM은 무엇을 믿어야 할까?

모델 내부 신호를 활용한 선택적 개입과 답변 신뢰성 연구

이화여자대학교 · 박세령, 손현경, 이다영 | 지도교수 황의원

> 틀린 문서의 영향은 줄이고, 맞는 문서로 답하던 능력은 지키는 것을 목표로 한다.

01 / WHY IT MATTERS

어느 한쪽만 믿으면 틀릴 수 있다

검색한 문서도, 모델이 기억한 정보도 항상 정확하지는 않다.

기억은 맞고, 문서는 틀릴 때

기억 A · 정답 ≠ 문서 B · 오답

문서를 그대로 따르면 오답이 된다.

→ 기존 지식 유지가 도움

기억은 틀리고, 문서는 맞을 때

기억 A · 오답 ≠ 문서 B · 정답

기억을 무조건 강화하면 오답이 된다.

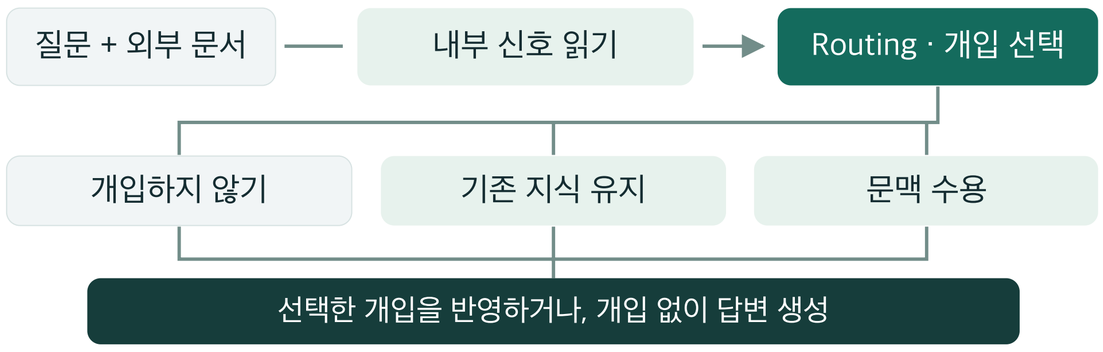
→ 올바른 문맥 수용이 도움

설명용 예시. 실제 추론에서는 정답을 알려주지 않고 내부 신호를 바탕으로 선택한다.

02 / OUR APPROACH

신호를 읽고, 필요한 개입을 선택한다

어텐션 헤드·은닉 표현 등에서 신호를 읽고, Routing으로 개입 여부·방향·강도를 선택한다.



별도 접근: 답변 분기를 비교하는 Packed

문서를 본 답변 ↔ 문서를 보지 않은 답변 → 분기 선택

두 분기를 한 입력 처리 호출에 담아 비교한다. Routing과의 결합은 후속 연구다.

One-pass Routing: 추론 중 신호로 개입을 결정하는 경로도 구현·분석한다.
Steering은 모델 가중치를 고정한 채 내부 활성값을 조절한다.
신호를 읽는 위치와 개입 위치는 구분하며, Router는 별도로 학습한다.

03 / WHAT WE OBSERVED

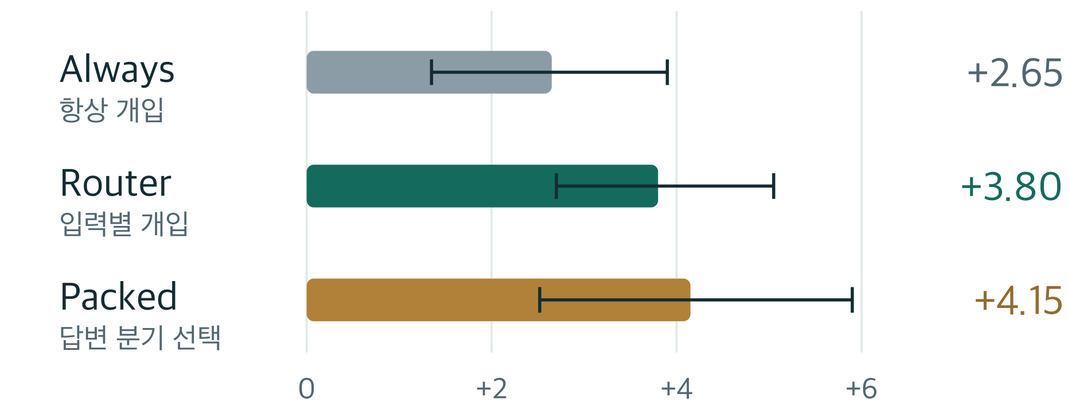
정답률 개선과 '맞히던 답 보호'를 함께 본다

ConFiQA-QA · 1,000개 질문 / 2,000개 입력 · 사실 정답 기준 정확 일치율(EM)

개입 전 정답률 **51.65%**

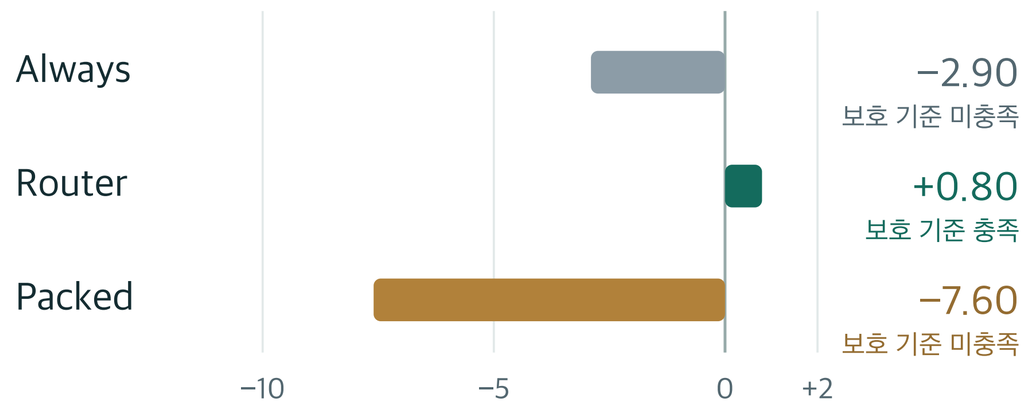
전체 정답률 변화

개입 전 대비 변화(%p) · 오차막대: 95% 신뢰구간



올바른 문맥(C+)에서의 변화

개입 전 대비 변화(%p) · 음수는 성능 저하



Router: 전체 개선과 함께
올바른 문맥의 성능 보호 기준을 충족했다.

Packed: 전체 정답률은 개선됐지만
올바른 문맥을 버리는 손상이 관찰됐다.

Router는 대상 ConFiQA 학습 fold의 정답으로 학습했고, Packed는 대상 라벨 없이 평가했다. 두 방법의 점수만으로 우열을 단정하지 않는다.
C+ 보호 기준(비열등): ΔEM의 95% 신뢰구간 하한 > −2%p. 하한은 Always −4.50, Router −0.60, Packed −9.50%p이며, 기준 충족이 C+ 개선 입증을 뜻하지는 않는다.

P8S 저장 행동 결과의 정책 평가(612질문): Router − Always = +0.82%p, 95% CI [−0.49, +2.21]. 유의한 우위는 미확인.

04 / TAKEAWAY & NEXT STEPS

상태를 읽는 능력과 좋은 답을 고르는 능력은 다르다.

개입의 성공 여부는 상태 분류 정확도만으로 판단할 수 없다.
실제 답변의 개선·손상과 추가 추론 비용을 함께 검증해야 한다.

다음 연구 질문

01 어떤 내부 신호가 개입 이득을 잘 예측하는가?
02 잘못된 기억을 고르는 분기 선택을 어떻게 줄일까?
03 외부 데이터에서도 효과와 비용이 유지되는가?

05 / RESEARCH PROGRESS

분석에서 응답 제어로

- 어텐션 헤드·은닉 표현의 지식-문맥 신호 분석
- Steering의 이득·손상 검증
- Routing·Packed 구현 및 외부 벤치마크·실패 분석

별도 성과: 지식-문맥 4-state 판독 연구

KSC 2026 투고 · 심사 중

2026 한국소프트웨어종합학술대회

자료: 팀 실험 기록·10/27 서면 보고, 공개 A1 정책 CSV 및 연구 결과 문서. 기준 모델: Llama-3.1-8B-Instruct.
실험 기록 기준: 2026-10-27 · 포스터 초안 v1: 2026-10-29
github.com/Ontology0/Graduation-Project

코드 · 결과 · 회의록
GitHub에서 확인