ALLTOLOGY

EWHA · CAPSTONE DESIGN 2026 · RESEARCH

LLM의 지식-문맥 충돌, 내부 신호로 답변을 조절하다

대규모 언어모델의 어텐션 헤드 분석에서 Routing·Steering 기반 선택적 개입까지

이화여자대학교 박세령 · 손현경 · 이다영 | 지도교수 황의원

ConFiQA-QA · Routing vs Base

+3.80%p

외부 평가 전체 정답률 변화

연구 목표 틀린 문서에 덜 흔들리고, 맞는 문서로 답하던 능력은 지키기.

01 검색한 문서도, 모델의 기억도 틀릴 수 있다

WHY

문서를 무조건 따르거나 기억을 무조건 강화하는 대신, 상황에 맞게 답변 방식을 바꿔야 한다.

상황 A · 문서에 오류가 있을 때

“호주의 수도는?”

모델의 기억 **캔버라** 정답 ≠ 오류가 있는 문서 **시드니** 오답

문서보다 기존 지식을 유지하는 것이 유리하다.

상황 B · 기억한 정보가 오래됐을 때

“오늘 도서관은 몇 시에 닫나요?”

모델의 기억 **18시** 오답 ≠ 최신 운영 공지 **20시** 정답

기억보다 올바른 문서를 수용하는 것이 유리하다.

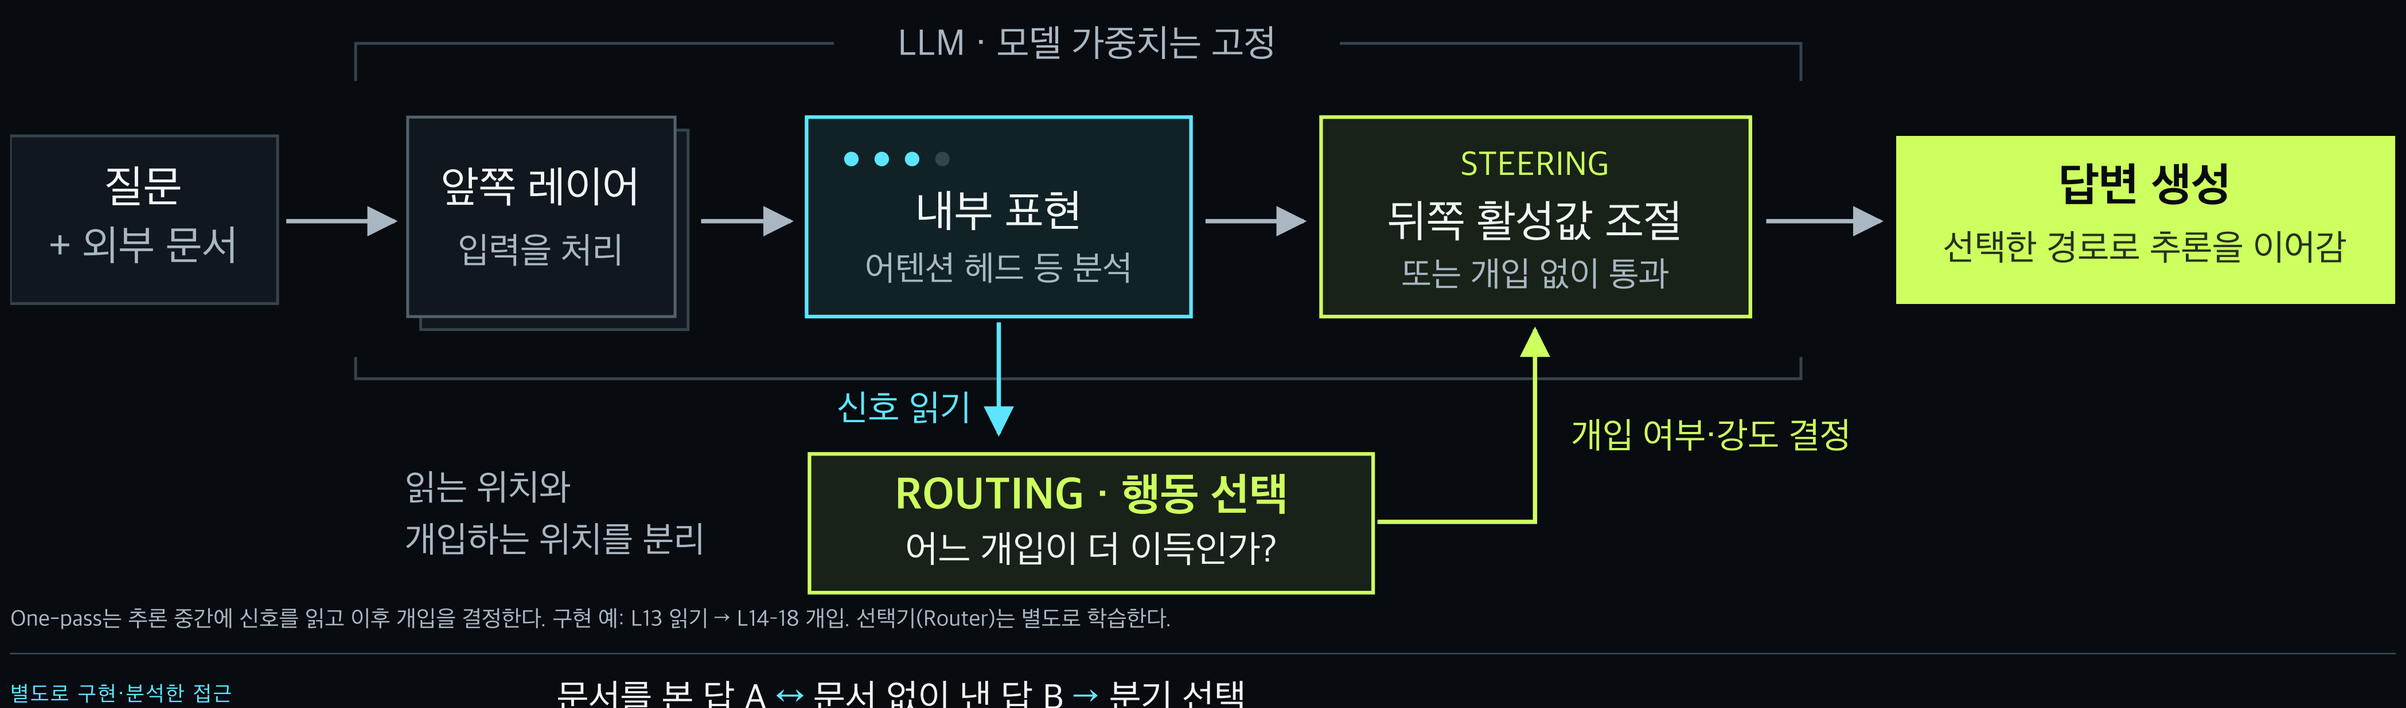
이해를 돕기 위한 가상 입력 예시이며 실제 평가 문항이 아니다. 추론 시에는 정답 여부를 알려주지 않는다.

02 내부 신호를 읽고, 필요한 개입만 선택한다

HOW

Routing은 개입을 고르고, Steering은 내부 활성값을 조절한다.

ONE-PASS ROUTING



One-pass는 추론 중간에 신호를 읽고 이후 개입을 결정한다. 구현 예: L13 읽기 → L14-18 개입. 선택기(Router)는 별도로 학습한다.

별도로 구현·분석한 접근

답변 비교 · Packed

문서를 본 답 A ↔ 문서 없이 낸 답 B → 분기 선택

두 경로를 한 입력 처리에 담아 비교한다. Routing과는 별도로 구현·평가한 접근이다.

03 정답률 개선과 ‘맞히던 답 보호’를 함께 검증했다

EVIDENCE

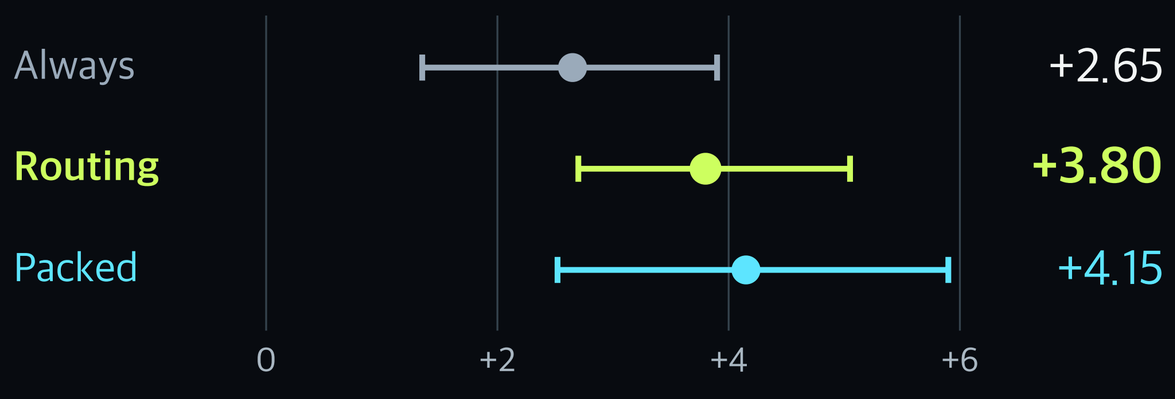
ConFiQA-QA · 1,000질문 / 2,000입력

사실 정답과의 정확 일치율(EM)로 평가 · 변화량 단위: %p

개입 전 정답률 **51.65%**

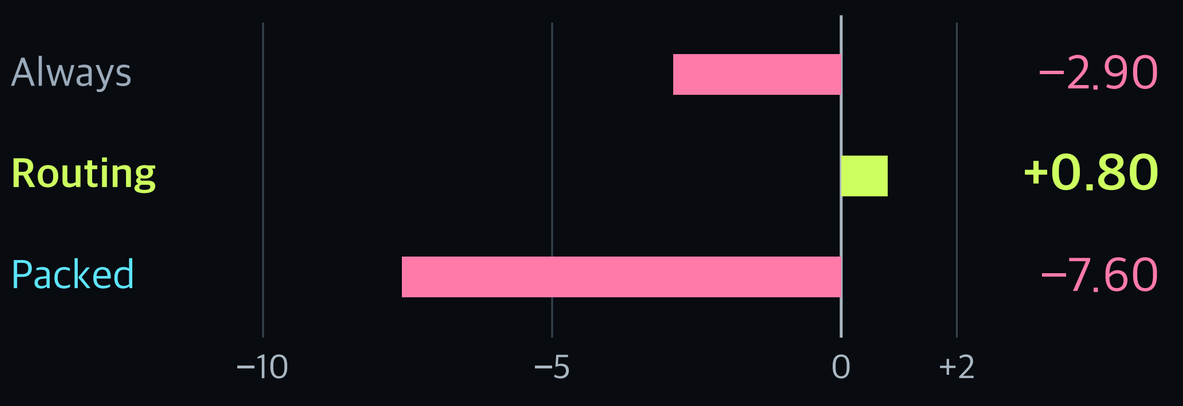
① 전체 정답률은 얼마나 좋아졌나?

개입 전 대비 변화 · 점: 평균, 선: 95% 신뢰구간



② 맞는 문서를 줬을 때는 괜찮을까?

올바른 문맥(C+)에서의 변화 · 왼쪽은 성능 손실



Routing은 전체 성능 개선과 C+ 허용 손실 기준을 충족.

다만 C+ 개선이 입증됐거나 손상이 전혀 없다는 뜻은 아니다.

Packed는 전체 성능이 올라도 C+ 손상이 컸다.

잘못된 문서에 강한 것과 올바른 문서를 지키는 것은 다르다.

Always: 모든 입력에 같은 Steering 적용. Routing: 개입을 선택. Packed: 두 답변 분기를 비교.

Routing은 대상 데이터의 학습 라벨을 사용하고, Packed는 대상 라벨 없이 평가했다. 서로 다른 조건이므로 최종 우열로 해석하지 않는다.

C+ 비열등 기준: 변화량의 95% CI 하한 > −2%p. Routing의 하한은 −0.60%p. 신뢰구간은 질문 단위 bootstrap 2,000회.

04 / TAKE-HOME MESSAGE

상태를 읽는 데서 끝내지 않고, 실제 답변의 이득과 손상까지 검증한다.

내부 신호 분석 → 선택적 응답 제어 구현 → 외부 평가·실패 분석.
다음 과제는 개입 선택의 일반화와 실제 추론 비용 검증이다.

관련 학술 성과 · 지식-문맥 4-state 판독

2026 한국소프트웨어종합학술대회(KSC 2026)

논문 투고 · 현재 심사 중

지식과 문맥의 정오 상태를 읽는 분석을
답변 제어와 구분되는 학술 연구로 발전시켰다.

공개 실험·연구 기록 github.com/Ontology0/Graduation-Project

결과 출처: 교수님 미팅 10/13·10/27 보고 및 저장소 docs/research_status.md

공개 연구 현황 · 2026.10 | 모델: Llama-3.1-8B-Instruct

코드와 연구 과정

GitHub 저장소 보기 →