이화여자대학교 · 2026 캡스톤디자인 · 연구 트랙 · 지도교수 황의원

팀 Alltology | **박세령** 4-state와 헤드 분석 실험, 논문·발표 | **손현경** Packed 외부 평가, C+ 손상 분석 | **이다영** Always·Router 외부 비교, 비교 하네스

ALLTOLOGY

기억과 문서가 다를 때, LLM은 무엇을 믿어야 할까?

LLM 내부 신호로 지식–문맥 4-state를 읽고, 상태에 맞는 선택적 개입을 고르는 연구

K = 모델이 기억한 답 · C = 검색 결과처럼 질문과 함께 받은 문서. 어느 쪽이 맞는지는 입력마다 다르고, 모델은 미리 알지 못한다.

코드와 실험 기록
공개 저장소에서 노트북과 결과 파일을 볼 수 있다

지식–문맥 4-state 판독 논문 · KSC 2026 투고 · 심사 중
2026 한국소프트웨어종합학술대회

1 배경과 차별점

왜 상태를 읽어야 하나

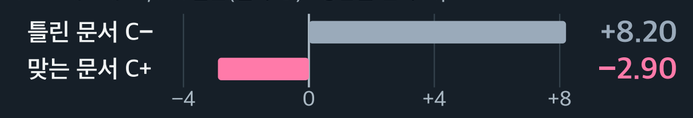
기억(K)과 문서(C)의 정오에 따라 네 가지 상태가 있다

	문서가 맞음 C+ 정답이 든 문서	문서가 틀림 C− 정답을 다른 답으로 바꾼 문서
기억이 맞음 K+ 문서 없이 답해도 정답	**K+C+** 둘 다 맞음 어느 쪽을 따라도 정답 362입력	**K+C−** "호주의 수도는?" 기억 캔버라 · 문서 시드니 **기억을 따라야 한다** 362입력
기억이 틀림 K− 문서 없이 답하면 오답	**K−C+** "도서관 마감은?" 기억 18시 · 문서 20시 **문서를 따라야 한다** 250입력	**K−C−** 둘 다 틀림 하나를 골라도 정답이 아니다 추가 근거 필요 250입력

굵은 테두리 두 칸이 주요 목표 상태다. 틀린 쪽을 따르면 맞힐 수 있던 답도 틀린다.
입력 수는 자체 실험셋 P8S 기준, 예시는 설명용 가상 입력.

모든 입력에 같은 개입을 하자, 맞는 문서 쪽 답이 줄었다

Always Steering: 모든 입력의 중간 계산값을 같은 방향으로 민다 · ConFiQA-QA 1,000질문(결과 ②) · 정답률 변화 %p



그래서 입력마다 상태를 읽고, 개입을 골라야 한다.

기존 접근과의 설계 전제 차이

접근	K·C 상태 판독	한계
문맥 충실 디코딩	구분하지 않음	틀린 문서를 따라간다
Always Steering	없음	맞는 문서의 답이 준다
이 연구 (제안) **4-state Routing**	Probe 판독(결과 ①)	통합 검증 진행 중

이 연구의 차별점

1. **네 상태를 모두 읽은 뒤 개입하는 구조**
   K+C−에서는 기억을, K−C+에서는 문서를 따르도록 상태별로 개입 방향을 고른다.
2. **어텐션 헤드 신호로, 한 번의 입력 처리 안에서 읽는다**
   L13 헤드 신호를 읽어 L14–18에 반영하는 One-pass 구조. 가중치는 고정하고 작은 Probe와 Router만 학습한다.
3. **판독과 답변 개선을 따로 측정한다**
   판독은 4-state Macro-F1, 답변은 정답률(EM) 변화로 보고하고, C+ 손상을 함께 적는다.

기대 효과 틀린 문서에 흔들리는 답은 줄이고, 맞는 문서로 답하던 능력은 지킨다.

2 제안 기법

구조와 학습 대상

Llama-3.1-8B-Instruct · 레이어 32개 · 가중치 고정 · 한 번의 입력 처리 안에서 읽고 개입한다 (One-pass)

질문 + 문서 (문서는 맞을 수도, 틀릴 수도 있다) → **L0–L12** (입력을 처리) → **L13 · 어텐션 헤드 32개** (선발한 헤드 조합의 신호를 읽는다 · 분할마다 1~32개 · 헤드별 128차원) → **Probe → 네 상태 판독** (별도로 학습한 작은 선형 분류기 · K+C+ · K+C− · K−C+ · K−C−) → **Routing · 개입 선택** (제안) (개입 안 함 · 기억을 지키는 방향 · 문서를 받아들이는 방향 중 하나) → **L14–18 · Steering** (계산값에 고른 방향을 더한다 · 가중치는 그대로) → **답변** (L19–31을 지나 생성)

읽는 위치 · L13 — 너무 이르면 단서가 부족하고, 너무 늦으면 반영할 계산이 남지 않는다

읽는 위치와 개입하는 위치를 분리

개입하는 위치 · L14–18

제안 구조. L13 헤드 신호로 네 상태를 읽고 이어지는 레이어에서 상태에 맞는 개입을 고른다. 판독(①)과 개입 선택(②)을 각각 검증했고, 둘을 K−C+ 한 상태로 이은 State-based는 ②에 있다. 네 상태 통합은 다음 단계다.

32개 헤드 중 역할별로 반복 선택된 후보 4개



H20	문서 정답 여부 · 충돌 여부	5/5
H10	문서 정답 여부	5/5
H19	문서 정답 여부	5/5
H3	충돌 여부	4/5

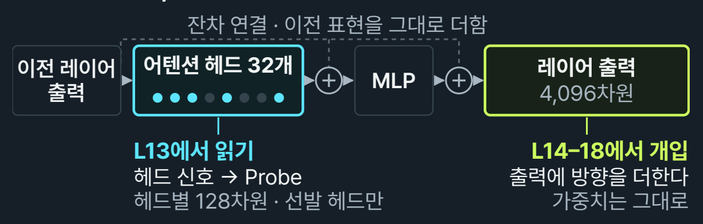
격자는 헤드 0–31 순 · 5회 중 선택 횟수 · 판독용 조합과 별개

L13 출력 전체와 판독 성능은 비슷하지만(0.6215 → 0.6306), 헤드 단위로 읽으면 어떤 헤드가 문서 정오·충돌 정보를 담는지 알 수 있다.

무엇을 학습하고 무엇을 고정하는가

LLM 가중치	고정
Probe	선형 분류기 · 정답 상태로 학습
Router	이득 예측기 · 학습 분할의 정답으로 학습
Packed	방향은 라벨 없이 갱신 · 기준값은 대상 dev로 정함

레이어 안에서, 어디를 읽고 어디에 더하나



3 결과 ① 상태를 읽을 수 있는가

판독 성능 · 4-state Macro-F1

선발 헤드 조합의 Probe는 네 상태를 **Macro-F1 0.6306**으로 구분한다(무작위 0.2477). Macro-F1은 네 상태를 고르게 맞히는 정도를 보는 0~1 점수로, 정답률이 아니다.

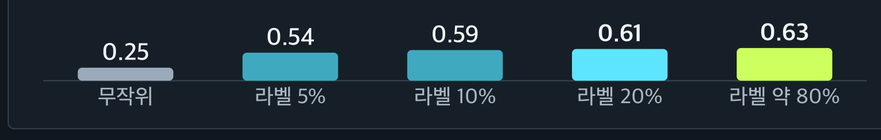
4-state Macro-F1 · 자체 실험셋 P8S 612질문 × 문서 2종 = 1,224입력

Llama-3.1-8B-Instruct · 질문 단위 5분할 교차검증 · 학습에 안 쓴 질문의 예측만 모아 계산 · 같은 질문의 두 문서는 같은 분할



라벨을 20%만 써도 판독 성능은 비슷했다

20%는 질문 122개로 학습해 나머지 490질문으로 평가(5회 평균), 약 80%는 질문 단위 5분할 교차검증 평균 · 평가 집합은 다름

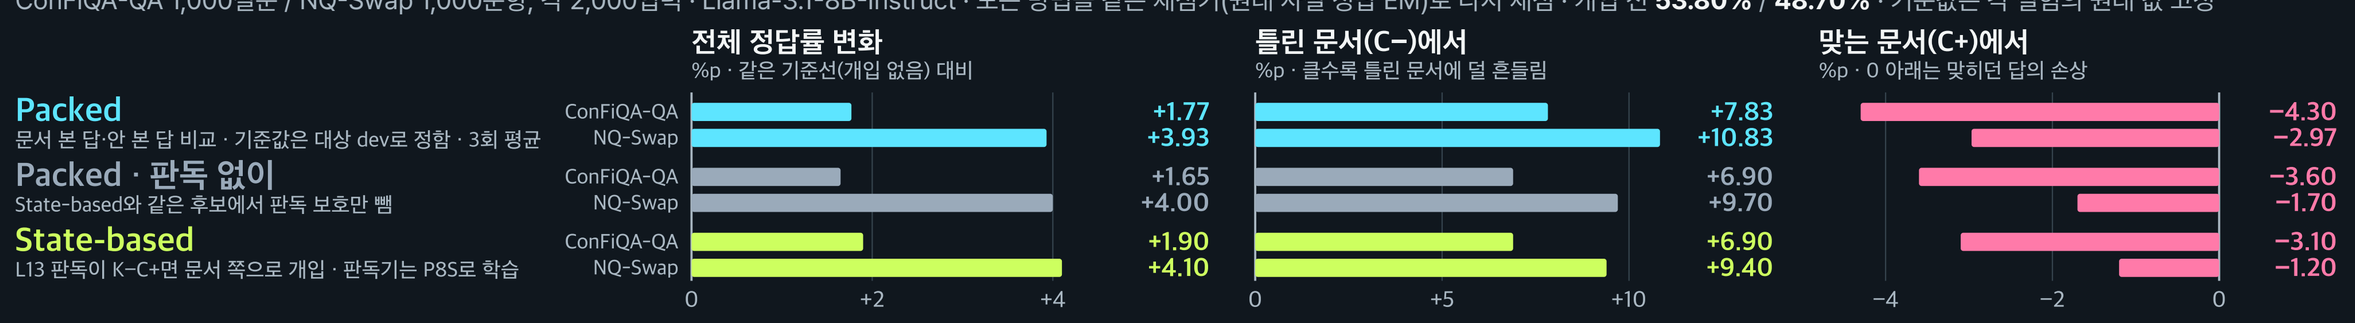


상태별 입력 수가 250~362개로 달라 네 상태를 같은 비중으로 보는 Macro-F1을 쓴다(같은 평가의 4-state 정확도 0.6422). Probe 없이 헤드 신호에 고정 기준만 둔 규칙은 0.3860에 그쳐, 판독에는 학습한 Probe가 필요하다. 답변 정답률은 결과 ②에서 따로 본다.

4 결과 ② 답이 실제로 좋아지는가

같은 데이터 재평가 · ConFiQA-QA · NQ-Swap

ConFiQA-QA 1,000질문 / NQ-Swap 1,000문항, 각 2,000입력 · Llama-3.1-8B-Instruct · 모든 방법을 같은 채점기(원래 사실 정답 EM)로 다시 채점 · 개입 전 **53.80%** / **48.70%** · 기준값은 각 실험의 원래 값 고정



같은 질문끼리 보면, State-based는 전체는 같고 C+ 손상이 적다

State-based − 비교 대상, %p · 회색 95% 신뢰구간		맞는 문서 C+	틀린 문서 C−	전체
Packed 대비	ConFiQA-QA	**+1.20** 0.23~2.20	**−0.93** −1.97~0.13	**+0.13** −0.58~0.85
	NQ-Swap	**+1.77** 0.64~2.99	**−1.43** −2.70~−0.23	**+0.17** −0.67~1.05
판독 없는 Packed 대비	ConFiQA-QA	**+0.50** 0.10~1.00	**0.00** 0.00~0.00	**+0.25** 0.05~0.50
	NQ-Swap	**+0.50** 0.10~0.98	**−0.30** −0.70~0.00	**+0.10** −0.10~0.35

이전 보고 · Always와 Router ConFiQA-QA

개입 전 대비 %p	전체	틀린 문서 C−	맞는 문서 C+
Always	**+2.65**	**+8.20**	**−2.90**
Router	**+3.80**	**+6.80**	**+0.80** 하한 −0.60

문서→질문 순서 프롬프트로 개입 전이 51.65%라 위와 섞지 않는다. Router는 학습 분할 정답으로 학습, Always 대비 +1.15(0.10~2.20), C+ 하한이 허용선 −2 안(비열등).

5 정리와 다음 단계

현재 결론 · 남은 검증

상태를 읽을 수 있다는 것과 좋은 답을 고를 수 있다는 것은 다르다.

판독을 붙이면 Packed의 C+ 손상이 줄지만(State-based), 개입 전 수준에는 못 미친다.

1. 최근 1~2년 선행 연구를 같은 모델·데이터로 재현해 전체·상태별 성능 비교 (진행 중)
2. 네 상태가 모두 있는 환경에서 4-state Routing의 상태별 효과 검증
3. 구성요소 추가·제거 비교와 온라인 추론 비용 측정으로 실제 개선에 필요한 요소만 남기기

수치 출처 · 중간발표 자료(자체 실험셋 P8S 판독 실험) · 같은 데이터 재평가(2026.11.09) · Always·Router 외부 평가 보고(2026.10)