

RAG에서 지식 충돌 완화를 위한 Preference Learning 기반 정렬 연구

Conflict-Aware PA-RAG

팀 03 · Alltology

이화여자대학교 캡스톤디자인 2026 · 지도교수: 황의원 교수님

박세령 (2276121) · 손현경 (2329019) · 이다영 (2317022)

목차

발표 순서

1. 문제 포착 — 왜 이 문제인가?
2. 연구 배경 · 가치 — PA-RAG가 다루지 않은 것
3. 관련 연구 — 기존 접근과 한계
4. 제안 솔루션 — Conflict-Aware PA-RAG
5. 기술 아키텍처 · MVP
6. 라이브 데모
7. AI 투명성 리포트
8. 결론 및 기대 효과
9. Q&A

팀 소개

Alltology

	박세령 (2276121)	손현경 (2329019)	이다영 (2317022)
역할	Conflict type 설계 RAG 파이프라인 구현	DPO 학습 설계 LoRA fine-tuning	데이터 파이프라인 평가 프로토콜
GitHub	@ryeong03	@bbberylll	@dev-ldy03

1. 문제 포착

RAG가 있어도 틀리는 경우가 있다

"Northwood Institute의 마스코트 색상은?"

	모델 내부 지식 (Parametric)	검색된 외부 문서 (Retrieved)
답변	deep blue	silver-green (2019 개정판)
근거	학습 당시 기억	실제 검색 결과

RAG 시스템이 외부 문서를 제공해도, 모델은 내부 지식을 고집하거나 맹목적으로 문서를 따를 수 있다.

2. 연구 배경 · 가치

PA-RAG가 다루지 않은 것

PA-RAG (NAACL 2025)는 RAG generator를 세 기준으로 정렬한다:

① Informativeness · ② Robustness · ③ Citation Quality

그러나 Knowledge Conflict — 검색 문서와 내부 지식이 충돌하는 상황 은 명시적 정렬 축에 없다.

충돌 상황	이상적 행동	PA-RAG의 한계
외부 문서가 최신·권위 정보	외부 우선	정렬 기준 없음 → 불일치
외부 문서가 부정확	내부 지식 또는 abstention	외부 맹신 가능
둘 다 불확실	불확실성 표현	확신 있는 오답

연구 질문: PA-RAG 프레임워크에 Knowledge Conflict 해소를 4번째 정렬 기준으로 추가하면, prompting 없이도 모델이 충돌을 올바르게 판단할 수 있는가?

3. 관련 연구

기존 접근의 한계

연구	방법	한계
PA-RAG (NAACL 2025)	DPO로 정보성·강건성·인용 품질 정렬	Knowledge Conflict를 명시적 기준으로 다루지 않음
ClashEval (2024)	내부 vs. 외부 충돌 현상 측정	해결 방법론 없음
ConflictBank (2024)	충돌 유형 분류 벤치마크	학습 기반 해결 없음
Prompting 접근	프롬프트로 외부 우선 지시	학습 없음, 일관성 한계

공통 한계: 충돌 해소를 외부 모듈(prompting·후처리)에 의존 — 모델 자체가 판단 기준을 갖지 못함

4. 제안 솔루션

Conflict-Aware PA-RAG

PA-RAG의 정렬 기준 3가지에 Knowledge Conflict 해소를 4번째 기준으로 추가

PA-RAG (기존)	→	Conflict-Aware PA-RAG (제안)
① Informativeness		① Informativeness
② Robustness		② Robustness
③ Citation Quality		③ Citation Quality
	+	④ Conflict Resolution ← 신규

학습 방식: DPO + LoRA (full fine-tuning 대신 경량화 → 학부 수준 자원에서 재현 가능)

데이터: ClashEval · ConflictBank (synthetic) → WikiContradict (natural, 한계 분석용)

4. 제안 솔루션 — 독창성

	기존 RAG	Prompting 기반	본 연구 (제안)
충돌 감지	✗	⚠ 프롬프트 의존	✓ 학습으로 내재화
일관성	✗	⚠ 프롬프트마다 다름	✓ 모델 내부 정렬
추가 비용	—	프롬프트 설계 비용	LoRA만 추가 학습
확장성	✗	제한적	✓ 다양한 conflict 유형

핵심 주장: Prompting으로 외부에서 지시하는 것보다, DPO+LoRA로 모델 내부에 내재화하는 것이 더 일관적이고 강건한 충돌 해소를 가능하게 하는가 — 를 실증한다.

5. 기술 아키텍처

시스템 구조



구현: `src/rag/` (10개 모듈) · FAISS 벡터스토어 · sentence-transformers 임베딩

5. 기술 아키텍처 — MVP 현황

컴포넌트	상태	비고
Base RAG 파이프라인	✅ 구현 완료	src/rag/ 10개 모듈
Conflict-Aware Prompting	✅ 구현 완료	configs/prompts/
실험 비교 데모 (HF Spaces)	✅ 배포 완료	실시간 Base vs CA 비교
저장소 문서 RAG 챗봇 (Telegram)	✅ 배포 완료	@alltology_rag_bot
DPO + LoRA 학습	🔧 Scaffold	src/training/
벤치마크 평가 파이프라인	🔧 Scaffold	src/evaluation/

DPO 학습 · 벤치마크 평가 파이프라인 구현 진행 중

6. 라이브 데모 ① — 실험 비교


HuggingFace Spaces

[ponyo03/conflict-aware-rag-demo](https://huggingface.co/spaces/ponyo03/conflict-aware-rag-demo)

- Base RAG vs Conflict-Aware 실시간 비교
- 샘플 질문으로 바로 테스트 가능
- 검색 문서 수(Top-K) 조정 가능

"What color is the Northwood Institute mascot after the 2019 revision?"

Base → deep blue / Conflict-Aware → silver-green




6. 라이브 데모 ② — RAG 챗봇

Telegram Bot

@alltology_rag_bot

- README · docs · CLAUDE.md를 청킹·임베딩
- 벡터 검색으로 관련 문맥 삽입 → LLM 답변 생성
- 저장소 내용 기반 Q&A 자동화



6. 라이브 데모 ③ — 연구 사이트

alltology.zapto.org

alltology.zapto.org

- 연구 배경 · 핵심 연구 질문 공개
- 실험 설계 · 관련 연구 정리

[Alltology](#) [research](#) [team](#) [github](#) [publication](#) 96 k Q

Alltology

이화여자대학교 졸업프로젝트 2026 · 연구 트랙 · 지도교수 황의원

Conflict-Aware PA-RAG — 검색 결과와 내부 지식이 충돌할 때, Preference Learning 기반 RAG 정렬 연구

PA-RAG의 세 가지 정렬 기준(informativeness, robustness, citation quality)을 확장하여, **internal knowledge**와 **external evidence**가 충돌하는 **knowledge conflict** 상황을 **DPO + LoRA**로 내재화할 수 있는지 탐구합니다.

연구 배경

LLM 기반 RAG 시스템에서 모델이 학습으로 알고 있는 것과 런타임에 검색된 문서가 **서로 다른 말을 할 때**, 어떻게 행동해야 하는지 명확한 기준이 없습니다. PA-RAG는 RAG generator를 preference optimization으로 정렬하지만, 위 충돌 케이스를 명시적으로 다루지 않습니다.

충돌 상황	올바른 행동
외부 문서가 최신 정보	외부를 따라야 함
외부 문서가 잘못된 정보	내부를 따라야 함
둘 다 불확실	불확실성을 표현해야 함

핵심 연구 질문

Internal knowledge와 external evidence가 충돌할 때, conflict resolution을 prompting이나 후처리 같은 외부 모듈로 둘 것인지, preference learning으로 모델에 **내재화**할 것인지 — 그리고 내재화한다면 **어디까지 가능한지**를

© Copyright 2026 Alltology · 이화여자대학교 졸업프로젝트 2026 · Powered by Jekyll & al-folio · Hosted by GitHub Pages.

6. 라이브 데모 ④ — 데모 · 팀

직접 해보기

- 🚀 웹 데모 · 텔레그램 봇 바로가기
- 팀원 소개 (박세령 · 손현경 · 이다영)
- GitHub 저장소 연동

🔗 실험 비교 데모 — Base RAG vs Conflict-Aware Prompting

Altology research team github publication 86 k 🔍 🌐

최근 질문한 Q: Conflict-Aware 실험에 관한 Q10을 확인해보셨나요. 후회: "What color is the Northwood Institute mascot after the 2019 revision?" — Base RAG는 내부 지식(deep blue), Conflict-Aware는 검색 문서 우선(silver-green)으로 답합니다.

🚀 웹 데모 열기

🔗 저장소 문서 RAG 챗봇 — Telegram Bot

GitHub 저장소의 README · docs · CLAUDE.md를 지식베이스로 청킹·임베딩한 뒤, 벡터 검색으로 관련 문맥을 찾아 Claude가 답변하는 RAG 챗봇입니다. 저장소 구조, 실행 방법, 연구 내용 등을 질문해보세요.

📩 텔레그램 봇 열기

팀원

	박세령	손현경	이다영
역할	Conflict type 설계 · 평가	DPO 학습 · LoRA fine-tuning	데이터 파이프라인 · RAG 파이프라인
GitHub	@ryeong03	@bbberyll	@dev-ldy03

저장소

연구 코드와 문서는 GitHub에서 관리합니다: [Ontology0/Graduation-Project](#)

© Copyright 2026 Altology · 이화여자대학교 졸업프로젝트 2026 · Powered by Jekyll & al-folio · Hosted by GitHub Pages.

7. AI 투명성 리포트

AI 활용 내역 (주요)

단계	사용 도구	AI 수행	인간 판단
선행 연구 분석	Claude, NotebookLM	논문 요약, 방법론 정리	원문 대조 검증, 범위 결정
레포 구조 설계	Cursor (Claude)	리팩토링, 파일 이동, import 수정	구조 방향 승인, 네이밍 결정
RAG 파이프라인 구현	Cursor (Claude)	모듈 코드 생성	모듈 분할 방식, 모델 선택
실험 설계	GPT-4o	데이터 스키마 초안	충돌 유형 정의, 평가 기준 결정

원칙: AI 출력은 항상 팀이 검토 후 채택 · 수정 · 거부 결정 → 모든 핵심 판단은 인간이 수행

8. 결론 및 기대 효과

- 요약
- 문제: PA-RAG는 Knowledge Conflict를 명시적 정렬 축으로 다루지 않음
 - 제안: DPO + LoRA로 conflict resolution을 모델에 내재화 (4번째 정렬 기준)
 - 현재: Base RAG + Conflict-Aware Prompting 구현 완료, 라이브 데모 배포 — DPO 학습 · 평가 진행 중

기대 효과

기여	내용
학술적	PA-RAG 확장 — conflict resolution을 preference learning으로 내재화하는 첫 시도
실용적	경량 (LoRA) 접근으로 학부 수준 자원에서 재현 가능한 파이프라인 공개
한계 분석	synthetic 학습이 natural conflict에 얼마나 전이되는지 측정

9. Q&A — 예상 질문 (1/2)

Q1. Prompting으로도 충분하지 않나요? 왜 굳이 학습인가요?

Prompting은 매 추론마다 명시적 지시가 필요하고, 프롬프트 설계에 따라 일관성이 달라집니다. DPO로 내재화하면 별도 지시 없이도 일관된 판단이 가능하다는 것을 실증하는 것이 본 연구의 핵심입니다.

Q2. DPO 학습 데이터는 어떻게 구성하나요?

ClashEval · ConflictBank의 conflict 쌍에서 chosen(올바른 판단) / rejected(잘못된 판단) 쌍을 구성합니다. 외부 문서가 권위 있을 때는 외부 우선, 오래됐거나 부정확할 때는 내부 우선 등 resolution rule을 레이블로 사용합니다.

9. Q&A — 예상 질문 (2/2)

Q3. 학습 후 다른 정렬 기준(informativeness 등)이 나빠지지 않나요?

PA-RAG의 기존 세 기준에 conflict 기준을 추가하는 구조라, 기존 정렬과 충돌하는지가 핵심 연구 질문(RQ4)입니다. 이 트레이드오프를 실험으로 측정하는 것이 본 연구의 중요한 기여 중 하나입니다.

Q4. 평가는 어떻게 진행하나요?

ClashEval · WikiContradict 벤치마크 기반 정량 평가와 Northwood 같은 케이스 스터디 정성 분석을 병행합니다. conflict resolution 정확도, 기존 정렬 기준 유지 여부(trade-off)를 핵심 지표로 측정합니다.

감사합니다

GitHub: github.com/Ontology0/Graduation-Project

데모 사이트: alltology.zapto.org

팀 03 · Alltology · 박세령 (2276121) · 손현경 (2329019) · 이다영 (2317022)