

RAG에서 지식 충돌 완화를 위한 Preference Learning 기반 정렬 연구

Conflict-Aware PA-RAG

작은 모델은 어디까지 배울 수 있는가 — LoRA 기반 지식 충돌 정렬의 한계 분석

팀 03 · Alltology

이화여자대학교 캡스톤디자인 2026 · 지도교수: 황의원 교수님

박세령 (2276121) · 손현경 (2329019) · 이다영 (2317022)

목차

발표 순서

1. 프로젝트 제목과 팀 소개
2. 문제 정의
3. 타겟 사용자와 사용 시나리오
4. 기존 방식의 한계
5. 솔루션 개요
6. 시스템 구조도
7. 핵심 기술 및 구현 내용
8. Live Demo 시나리오
9. 구현 결과 및 현재 완성도 / 파일럿 실험 결과
10. 한계와 향후 개선 방향
11. 팀원별 역할 및 기여
12. GitHub / 배포 URL / 참고자료
13. AI 투명성 리포트
14. Q&A 세션
15. 지도교수 의견서

1. 프로젝트 · 팀 소개

Conflict-Aware PA-RAG | Alltology

	박세령 (2276121)	손현경 (2329019)	이다영 (2317022)
역할	Conflict type 설계 RAG 파이프라인 구현	DPO 학습 설계 연구 설계 · 파일럿 실험	데이터 파이프라인 평가 프로토콜
GitHub	@ryeong03	@bbberylll	@dev-ldy03

2. 문제 정의

Knowledge Conflict — 검색 문서 vs 내부 지식

"Northwood Institute의 마스코트 색상은?" (2019년 개정)

	모델 내부 지식 (Parametric)	검색된 외부 문서 (Retrieved)
답변	deep blue	silver-green ✓
근거	학습 당시 기억	실제 최신 문서

충돌 상황	이상적 행동	실제 문제
외부 문서가 최신·권위 정보	외부 우선	내부 지식 고집
외부 문서가 부정확	내부 지식 또는 abstention	외부 맹신
둘 다 불확실	불확실성 표현	확신 있는 오답

3. 타깃 사용자와 사용 시나리오

누가, 어떤 상황에서?

타깃	문제 상황
NLP/RAG 연구자	Prompting vs LoRA 내재화 — 충돌 해소 방법론 비교 연구
RAG 시스템 개발자 · 기업	사내 최신 문서가 모델의 기존 지식과 충돌하는 프로덕션 환경
학부 연구자	DPO + LoRA 경량 파이프라인을 제한된 자원으로 재현하려는 연구자

사용 시나리오

- ① 기업 정책 봇: "2024년 개정 육아휴직 규정" 문서 vs 모델 기존 기억 충돌 → 최신 규정으로 정확히 답변
- ② 의료 가이드라인 QA: 개정 임상 지침 vs 학습 당시 구 지침 충돌 → 외부 근거 우선
- ③ 학술 QA: 논문 내용과 모델이 아는 "상식"이 다를 때 → 논문 우선 또는 불확실성 표현

4. 기존 방식의 한계

PA-RAG · Prompting · 벤치마크

연구 / 접근	방법	한계
PA-RAG (NAACL 2025)	DPO로 Informativeness · Robustness · Citation 정렬	Knowledge Conflict를 명시적 정렬 기준으로 다루지 않음
Prompting 접근	외부 우선 지시를 프롬프트에 삽입	매 추론마다 명시 필요, 일관성 불안정
ClashEval (2024)	내부 vs. 외부 충돌 현상 측정	해결 방법론 없음 — 현상 측정만
ConflictBank (2024)	충돌 유형 분류 벤치마크	학습 기반 해결 없음

공통 한계: 충돌 해소를 외부 모듈(prompting · 후처리)에 의존 —
모델 자체가 판단 기준을 갖지 못함

5. 솔루션 개요 ①

Conflict-Aware PA-RAG

PA-RAG의 정렬 기준 3가지에 **Knowledge Conflict** 해소를 4번째 기준으로 추가

PA-RAG (기존)	→	Conflict-Aware PA-RAG (제안)
① Informativeness		① Informativeness
② Robustness		② Robustness
③ Citation Quality		③ Citation Quality
	+	④ Conflict Resolution ← 신규

학습 방식: DPO + LoRA · 학부 수준 자원에서 재현 가능 (full fine-tuning 미사용)

데이터: ClashEval · ConflictBank (synthetic) → WikiContradict (natural, 전이 분석)

5. 솔루션 개요 ②

독창성 · 5-Arm 실험 설계

#	Arm	학습	역할
1	Base RAG	없음	기본 하한선
2	Conflict-Aware Prompting	없음	프롬프트만으로 충돌 처리
3	PA-RAG-style LoRA	DPO+LoRA	conflict 없이 PA-RAG식 정렬
4	Conflict-Aware RAG LoRA	DPO+LoRA	conflict preference만 학습
5	Conflict-Aware PA-RAG LoRA	DPO+LoRA	PA-RAG + conflict (제안)

핵심 질문: Arm 2 (prompting) vs Arm 5 (LoRA 내재화) — 어느 쪽이 더 일관적이고 강건한 충돌 해소를 하는가?

6. 시스템 구조도



구현: `src/rag/` (10개 모듈) · FAISS 벡터스토어 · sentence-transformers 임베딩

7. 핵심 기술 및 구현 내용

AI / 학습

역할	기술
Preference Learning	DPO (TRL)
경량 Fine-tuning	LoRA / PEFT
런타임	PyTorch · Hugging Face <code>transformers</code>

RAG 파이프라인 — `src/rag/` (10개 모듈)

모듈 그룹	구성
문서 처리	<code>document_loader</code> · <code>chunker</code>
검색	<code>embedder</code> (MiniLM) · <code>vector_store</code> (FAISS) · <code>retriever</code>
생성	<code>prompt_builder</code> · <code>generator</code> · <code>pipeline</code> (오케스트레이터)

8. Live Demo 시나리오 ①

데모 영상

▶ youtu.be/qc0GkgJoBBk

HuggingFace Spaces — Base vs Conflict-Aware 실시간 비교

[ponyo03/conflict-aware-rag-demo](https://huggingface.co/spaces/ponyo03/conflict-aware-rag-demo)

"What color is the Northwood Institute mascot after the 2019 revision?"

Base RAG → deep blue / Conflict-Aware → silver-green ✓

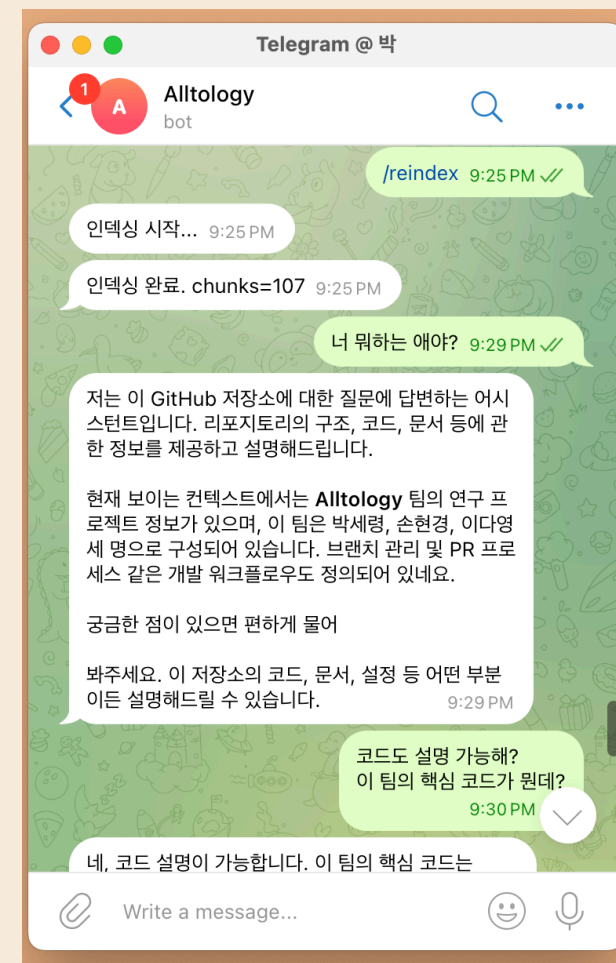
- Top-K 검색 수 조정 · 샘플 질문으로 바로 테스트 가능

8. Live Demo 시나리오 ②

Telegram RAG 봇

@alltology_rag_bot

- README · docs · CLAUDE.md를 청킹·임베딩
- 벡터 검색 → 문맥 삽입 → LLM 답변 생성
- `/about` · `/run` · `/where <키워드>` 지원




8. Live Demo 시나리오 ③

연구 사이트

alltology.zapto.org

- 연구 배경 · 핵심 연구 질문 공개
- 실험 설계 · 관련 연구 정리
- HuggingFace · Telegram 버튼 연동



9. 구현 결과 및 현재 완성도

컴포넌트	상태	비고
Base RAG 파이프라인	✓ 완료	<code>src/rag/</code> 10개 모듈
Conflict-Aware Prompting	✓ 완료	<code>configs/prompts/</code>
HuggingFace Spaces 데모	✓ 배포 완료	Base vs CA 실시간 비교
Telegram RAG 봇	✓ 배포 완료	@alltology_rag_bot
연구 사이트	✓ 운영 중	alltology.zapto.org
데모 영상	✓ 공개	youtu.be/qc0GkgJoBBk
DPO + LoRA 학습	🔧 Scaffold	<code>src/training/</code>
벤치마크 평가 파이프라인	🔧 Scaffold	<code>src/evaluation/</code>

9-1. 파일럿 실험 결과

모델 규모별 충돌 해소 능력 — upper / lower bound 매핑

실험	셋업	핵심 결과
exp1 ClashEval 기본	거짓 문서 판별	Base 50% → Conflict-Aware 100% (거짓 문서 거부율)
exp2 A/B/C 타입 분해	문서 구성 3종 분리	A(거짓만) Base 50% vs CA 83% · B·C는 둘 다 100%
exp3 temporal (명시적)	내부 옛 지식 vs 외부 최신 ("2023년 변경")	두 arm 모두 update 100% — 문서가 친절해 추론 불필요
exp4 temporal (암묵적)	변화 설명 없이 최신 사실만 전제	두 arm 모두 100% — 강한 모델 천장효과

결론: 강한 모델 = upper bound(충돌 거의 자동 해결) · 약한 모델(phi-2) = lower bound(exp1 실패)
→ 핵심 질문: 작은 모델(Llama 3.1-8B)을 LoRA/DPO로 upper bound까지 끌어올릴 수 있는가?

10. 한계와 향후 개선 방향

현재 한계

- DPO 학습 미완 → 정량적 실험 결과 미공개 (파이프라인·설계 단계 완료)
- Synthetic 데이터 학습 시 Natural conflict 전이 성능 불확실
- 자원 한계로 full fine-tuning 미구현 (LoRA 경량화로 대체)
- 벤치마크 자동 평가 파이프라인 미완료

향후 개선 방향

단계	계획
단기	DPO 학습 완료 · ClashEval 벤치마크 정량 평가 실행
중기	WikiContradict 자연 충돌 실험 — synthetic → natural 전이 측정
장기	특정 도메인(의료·생활검색 등)에서 강건하게 작동하는 conflict-aware 모델 구축 (general → domain 확장)

11. 팀원별 역할 및 기여

	박세령	손현경	이다영
주요 담당	Conflict type 설계 RAG 파이프라인	DPO 학습 설계 LoRA fine-tuning	데이터 파이프라인 평가 프로토콜
주요 기여	src/rag/ 10개 모듈 구현 레포 구조·문서화 총괄 연구 사이트 운영	RQ 구체화·검증, 파일럿 실험 설계·진행·검증 HF Spaces 배포·DPO scaffold 구현 Conflict preference 데이터 설계	data/schema/ 설계 벤치마크 선정 전략 평가 루브릭 설계
GitHub	@ryeong03	@bbbberylll	@dev-ldy03

공통: 연구 방향 설계 · AI 출력 교차 검증 · 핵심 로직 판단 — 전원 참여

12. GitHub / 배포 URL / 참고자료

배포 링크

서비스	URL
GitHub 저장소	github.com/Ontology0/Graduation-Project
연구 사이트	alltology.zapto.org
HF Spaces 데모	huggingface.co/spaces/ponyo03/conflict-aware-rag-demo
Telegram RAG 봇	@alltology_rag_bot
데모 영상	youtu.be/qc0GkgJoBBk
발표 슬라이드	github.com/Ontology0/Graduation-Project/blob/dev/docs/presentation.md

참고 논문

논문	출처
PA-RAG: Preference Alignment for RAG	NAACL 2025
ClashEval: Benchmarking LLM Dilemma	arXiv 2024
ConflictBank: Knowledge Conflicts	arXiv 2024

13. AI 투명성 리포트

AI 활용 내역 (주요)

단계	사용 도구	AI 수행	인간 판단
선행 연구 분석	Claude, NotebookLM	논문 요약, 방법론 정리	원문 대조 검증, 범위 결정
레포 구조 설계	Cursor (Claude)	리팩토링, 파일 이동, import 수정	구조 방향 승인, 네이밍 결정
RAG 파이프라인 구현	Cursor (Claude)	모듈 코드 생성	모듈 분할 방식, 모델 선택
Telegram RAG 봇	Cursor (GPT-5)	UX·보안·운영 문서화	공개 범위, allowlist 정책 확정
파일럿 실험	Claude(haiku/sonnet) · gpt-4o-mini	데이터 스키마 초안, 실험 코드 보조	충돌 유형 정의, 평가 기준 결정, 결과 해석

상세: [docs/ai_transparency_report.md](#)

14. Q&A 세션 ①

Q1. Prompting으로도 충분하지 않나요? 왜 굳이 학습인가요?

Prompting은 매 추론마다 명시적 지시가 필요하고, 프롬프트 설계에 따라 일관성이 달라집니다. DPO로 내재화하면 별도 지시 없이도 일관된 판단이 가능하다는 것을 실증하는 것이 핵심입니다.

Q2. DPO 학습 데이터는 어떻게 구성하나요?

ClashEval · ConflictBank의 conflict 쌍에서 chosen(올바른 판단) / rejected(잘못된 판단) 쌍을 구성합니다. 외부 문서가 권위 있을 때는 외부 우선, 부정확할 때는 내부 우선 등 resolution rule을 레이블로 사용합니다.

14. Q&A 세션 ②

Q3. 학습 후 informativeness 등 기존 기준이 나빠지지 않나요?

이 트레이드오프가 핵심 RQ4입니다. PA-RAG 기존 세 기준 + conflict 기준을 함께 실험하면서 trade-off를 측정하는 것이 중요한 기여입니다.

Q4. 평가는 어떻게 진행하나요?

ClashEval · WikiContradict 벤치마크 기반 정량 평가와 케이스 스터디 정성 분석을 병행합니다. Conflict resolution 정확도, 기존 정렬 기준 유지 여부(trade-off)를 핵심 지표로 측정합니다.

15. 지도교수 의견서

지도교수 의견 (요약)

프로젝트	Conflict-Aware PA-RAG — PA-RAG가 다루지 않은 knowledge conflict를 preference learning으로 정렬
지도교수	황의원 · 팀 03 Alltology

연구 방향 · 진행

- PA-RAG 미해결 지점(knowledge conflict)을 정확히 짚어 문제 설정이 타당
- 매주 토요일 정기 회의·여름방학 면담 일정 등 권고 일정을 충실히 이행
- 지도 방향: ① 단순 성능 비교 → 한계·유형 분석 framing ② 범위 명시적 제한(LoRA, conflict type 3~4개) ③ 공개 벤치마크 우선·자연 conflict는 case study

현재 성과 · 향후 과제

- Base RAG · conflict-aware prompting 동일 코드베이스 구현 완료, phi-2 파일럿으로 초기 신호 확인
- 연구 페이지·데모 직접 구축·공개 — 구현·협업 역량 높이 평가
- 벤치마크(ClashEval · ConflictBank · WikiContradict)·연산 자원 확보 — 핵심 과제는 방법론 정합성(resolution rule, synthetic→natural 전이, trade-off)
- 여름방학 면담으로 단계 점검 · general → 도메인 확장 · ACL/EMNLP/NAACL 등 장기 목표

종합: 기반 논문의 명확한 확장점, 정직한 범위 설정, 충실한 사전 구현을 갖추어 졸업프로젝트로서 적절하다고 판단함.

지도교수 황의원

줄업프로젝트 팀 03 (Alltology) — 「RAG에서 지식 충돌 완화를 위한 Preference Learning 기반 정렬 연구 (Conflict-Aware PA-RAG)」 지도 교수 의견서

지도교수: 황의원

본 팀은 PA-RAG(NAAACL 2025)를 기반 논문으로 삼아, 해당 연구가 다루지 않은 knowledge conflict(검색된 외부 근거와 모델 내부 지식의 충돌) 상황을 preference learning으로 정렬하는 방향을 제안하였습니다. 기반 논문의 미해결 지점을 정확히 짚어 연구 문제를 도출하였고, 이를 "내부 지식과 외부 지식 활용의 결합"이라는 문제로 자연스럽게 연결한 점에서 문제 설정이 타당하다고 판단됩니다.

진행 과정에서 본 팀은 학기 중 매주 토요일 정기 팀 회의를 꾸준히 이어왔으며, 여름방학에도 교수 면담을 수요일로 먼저 제안하고 토요일 팀 회의 또한 동일하게 유지하기로 하였습니다. 또한 학기 초 첫 면담에서 권하였던 진행 방향 — 여름방학 이전에 연구 방향을 확정하고 예비 실험까지 진행한 뒤 방학부터 본격적인 실험에 착수한다는 일정 — 을 충실히 이행해 왔다고 생각합니다.

연구가 진행되는 동안 다음과 같은 방향을 지도하였으며, 팀이 이를 적절히 수용하여 최종 면담을 진행하였습니다. 첫째, 연구 framing을 단순 성능 비교가 아니라 한계 분석(어떤 유형의 충돌이 학습으로 내재화되고 어떤 유형이 한계인가)으로 가져갈 것을 권하였습니다. 이는 학부 수준에서 더 정직하고 방어 가능한 구조이며, 사전 가설을 명시한 뒤 검증하는 형태로 설계하도록 지도하였습니다. 둘째, 학부 자원의 한계를 고려하여 문제 범위를 명시적으로 제한할 것을 권하였습니다. Full fine-tuning은 직접 수행하지 않고 PA-RAG 원논문 수치를 인용 비교군으로 활용하며, conflict type을 3~4개로 한정하되 "대표 유형을 커버한다"는 논리로 결론짓는 방식이 적절하다고 보았습니다. 셋째, 데이터 전략에 대해 자체 제작보다 공개 벤치마크 활용을 우선하고, 자연 conflict는 수집 부담이 크므로 case study 수준의 정성 분석으로 한정하도록 조언하였습니다.

지금까지 본 팀은 Base RAG 파이프라인과 conflict-aware prompting을 동일 코드베이스에서 비교 가능한 형태로 구현 완료하였고, 소규모 모델(phi-2) 기반 파일럿을 통해 프롬프트 차이만으로 충돌 상황의 답변이 달라질 수 있다는 초기 신호를 확인하였습니다. 이 파일럿은 표본이 작아 방법론의 효과를 입증하는 단계는 아니나, 본 실험 진행의 타당성을 뒷받침하는 사전 검증으로서 충분하다고 판단됩니다. 아울러 연구 페이지와 데모 환경을 직접 구축·공개함으로써 구현 역량과 팀 협업 과정을 외부에서도 확인할 수 있도록 한 점은 높이 평가할 만합니다.

데이터와 연산 자원 측면의 기반도 상당 부분 갖추어진 상태입니다. 평가·학습에 활용할 공개 벤치마크 후보군(ClashEval, ConflictBank, WikiContradict 등)이 학습용·평가용·정성분석용으로 활용 계획이 잘 구성되어 있으며, DPO 학습에 필요한 연산 자원 또한 예산이 확보되어 현실적인 실험 진행 계획이 마련된 상황이라고 판단됩니다. 따라서 앞으로의 핵심 과제는 자원 조달이 아니라 방법론의 정합성에 있습니다. 구체적으로 (1) chosen/rejected를 결정하는 resolution rule의 학술적 정당성 확보 — 라벨이 자명한 합성 케이스로 학습을 한정하는 우회 전략의 타당성, (2) 합성 conflict로 학습한 정렬이 자연 conflict로 얼마나 전이되는지의 검증, (3) conflict 정렬이 기존 정렬 기준(informativeness 등)을 훼손하지 않는지의 trade-off 측정이 남아 있습니다.

이러한 과제들은 여름방학 정기 면담을 통해 단계적으로 점검할 예정이며, general 도메인에서 먼저 결과를 확보한 뒤 의료·생활검색 등 특정 도메인으로 확장하는 순서로 진행하도록 지도하였습니다. 더불어 연구가 일정 수준 이상 진척될 경우, ACL, EMNLP, NAAACL 등 자연어처리 분야 주요 학회나 관련 워크숍에의 논문 투고를 장기 목표로 두고 있습니다. 또한 본 줄업 프로젝트에 관심 있는 본 연구실 석사 과정 학생과의 협업을 연결하여 연구의 확장 가능성을 넓히는 방안도 함께 고려하고 있습니다.

종합적으로 본 연구는 기반 논문의 명확한 확장점, 정직한 범위 설정, 그리고 충실한 사전 구현을 갖추고 있어 줄업프로젝트로서 적절하다고 판단합니다.

2026년 06월 01일

지도교수 : 황의원 (인)

감사합니다

GitHub: github.com/Ontology0/Graduation-Project

데모 사이트: alltology.zapto.org

데모 영상: youtu.be/qc0GkgJoBBk

HuggingFace: [ponyo03/conflict-aware-rag-demo](https://huggingface.co/ponyo03/conflict-aware-rag-demo)

팀 03 · Alltology · 박세령 (2276121) · 손현경 (2329019) · 이다영 (2317022)